Zadanie 1: Korpusy anotowane oraz osadzenia słów i tekstów

Opracowanie: dr inż. Arkadiusz Janz, dr hab. inż. Maciej Piasecki prof. PWr

Czas wykonania: 2 tygodnie (oddanie lab 3)

Korpus językowy jest zbiorem tekstów, który stanowi podstawowy zasób praktycznie w każdym zadaniu związanym z przetwarzaniem języka naturalnego. Przy pomocy wielkich korpusów można budować ogólne reprezentacje językowe, szukać kontekstów występowania słów, a także analizować specyficzne konstrukcje składniowe i semantyczne w danym języku (lub językach - w przypadku korpusu wielojęzycznego). Mniejsze korpusy często są także ręcznie wzbogacane o dodatkowe metadane, dzięki czemu możliwe jest wykorzystanie takich danych w uczeniu maszynowym do zadań klasyfikacji całych dokumentów, zdań, a także fraz, czy też pojedynczych słów. Elektroniczne wersje korpusów tekstowych służą do prowadzenia badań nad językiem, tworzenia słowników, wyszukiwarek, a także systemów tłumaczenia maszynowego, określania stylu literackiego, rozpoznawania wydźwięku i emocji, ujednoznaczniania znaczeń słów, wydobywania nazw własnych i wielu innych zastosowań.

Często wyzwaniem dla badaczy jest określenie składu korpusu, czyli takiego doboru tekstów, by były one reprezentatywne z perspektywy konkretnego problemu do rozwiązania. W kontekście budowania wielkich, ogólnych modeli językowych, istotne jest zebranie jak największej liczby tekstów z różnych źródeł, dziedzin oraz stylów wypowiedzi (książki, artykuły, blogi, komentarze, recenzje, itp.). Często jednak problemy są bardzo specyficzne i ukierunkowane dziedzinowo, np.:

- detekcja fałszywych wiadomości dotyczących COVID-19,
- rozpoznawanie wydźwięku opinii pacjentów o lekarzach,
- określanie autorstwa tekstów literackich,
- wydobywanie nazw hoteli w ofertach turystycznych,
- predykcja kursów giełdowych na podstawie tekstów ekonomicznych,
- budowa systemu dialogowego dla użytkowników operatorów telefonicznych,
- konstrukcja chatbota dla petentów Urzędu Miejskiego Wrocławia,
- utworzenie wirtualnej sekretarki lekarza pierwszego kontaktu,
- wykrywanie mowy obraźliwej w komentarzach na Twitterze,
- streszczanie artykułów prasowych.

W każdym z wyżej wymienionych przypadków należy utworzyć tzw. korpus reprezentatywny dla danej dziedziny. Modele językowe powstałe z wielkich i ogólnych korpusów językowych można stosować do tego typu zadań, lecz często wcześniej dostraja się je (ang. fine-tuning) na korpusach wzorcowych. Z założenia korpusy wzorcowe mają pomóc w realizacji zadania, gdyż zawierają teksty z konkretnej dziedziny, zawierają specyficzne dla danego problemu słownictwo, określone konstrukcje leksykalno-składniowo-semantyczne i dzięki temu spodziewamy się poprawy jakości działania metody dostrojonej na takim korpusie.

Część I

Anotacja (5 pkt)

Należy wykonać anotację wybranego zbioru danych zgodnie z procedurą 2+1. W trakcie anotacji należy monitorować poziom zgodności (2 iteracje) oraz aktualizować wytyczne (po iteracji 1). W anotacji należy **posłużyć się zbiorami dostarczonymi w ramach instrukcji lub własnym zbiorem danych** (np. powiązanym z projektem naukowo-wdrożeniowym).

Plan realizacji ćwiczenia

1. Wczytać wybrany korpus tekstów i przygotować do anotacji **[1pkt]**
1. Ustalić wytyczne anotacji i wykonać anotację w wybranym narzędziu (np. Docanno - https://github.com/doccano/doccano , Google Spreadsheets) **[1pkt]**
    a. Zapisać wytyczne w formie krótkiej notatki dla anotatorów
    b. Anotacja przeprowadzona na poziomie całego tekstu
    c. Anotacja na poziomie poszczególnych fragmentów tekstu
    d. Należy pamiętać o dobrych praktykach anotacji (niezależność anotacji poszczególnych anotatorów, próbka dobrana losowo, itd.)
2. Wykonać eksport oetykietowanych danych i wyliczyć zgodność **[0.5pkt]**
    a. Wyliczyć wartość Kappy Cohena
    b. Wyliczyć wartość Kappy Fleissa
3. Ustalić nowe wytyczne i powtórzyć anotację na nowej próbce danych **[1pkt]**
4. Ponownie wyliczyć zgodność i porównać z wart. z pierwszej iteracji **[0.5pkt]**
    a. Wyliczyć wartość Kappy Cohena
    b. Wyliczyć wartość Kappy Fleissa

5. Jeśli osiągnięto odpowiedni poziom zgodności, należy zaanotować pozostałą część zbioru (każda osoba anotuje po N niezależnych przykładów)
6. Zwięźle podsumować pozyskany zbiór za pomocą statystyk opisowych [**1 pkt**]

Sugerowane zbiory danych

1. Zbiór PolEmo
https://clarin-pl.eu/dspace/handle/11321/710
- Własną anotację można porównać z anotacją dostarczoną w ramach korpusu
- W ramach anotacji fragmentów tekstu sugeruje się wykonanie anotacji aspektów (ang. Aspect-based Sentiment Analysis) lub modyfikatorów wydźwięku na poziomie fraz (wzmacnianie, osłabianie, odwracanie polaryzacji)

2.Detekcja mowy nienawiści
https://huggingface.co/datasets/poleval/poleval2019_cyberbullying
- Należy posłużyć się biblioteką *`huggingface datasets`*, aby wczytać zbiór.
- W ramach anotacji fragmentów tekstu sugeruje się wykonanie anotacji aspektów lub modyfikatorów opinii na poziomie fraz (wzmacnianie, osłabianie, odwracanie)

3. Inne, własne zadania:
- emocje w komentarzach filmowych
- fake newsy i dezinformacja
- styl i autorstwo
- opinie pacjentów o lekarzach
- …

Sugerowana literatura

Handbook of Linguistic Annotation, Nancy Ide, James Pustejovsky, Springer, 2017; sugerowany artykuł: „Inter-Annotator Agreement'' (s. 297)

Artykuł o anotacji wydźwięku (Sentiment):
https://medium.com/besedo-engineering/sentiment-analysis-part-3-data-annotation-d0845d1a8a1b

Artykuł o anotacji jednostek nazewniczych (NER)
https://medium.com/@rongqianhui/named-entity-recognition-annotation-schemes-e684f9cd5a56

DiaBiz.Kom – Towards a Polish Dialogue Act Corpus Based on ISO 24617-2 Standard, https://aclanthology.org/2022.coling-1.320.pdf

Artykuł o Docanno
https://towardsdatascience.com/doccano-a-tool-to-annotate-text-data-to-train-custom-nlp-models-f4e34ad139c3

Część II

Pre-trenowane modele przestrzeni wektorowych służą do modelowania różnorodnych zjawisk językowych występujących w korpusach tekstów. W niniejszej części należy zapoznać się z podstawowymi metodami tworzenia modeli przestrzeni wektorowych (model worka słów (ang. Bag-of-Words) i TF-IDF, Word2Vec, Fasttext, GloVe) oraz zastosować wybrane modele przestrzeni wektorowych do analizy tekstów oraz ich anotacji. Należy zestawić rezultaty otrzymane za pomocą wybranych modeli osadzania słów i algorytmów grupowania czy redukcji wymiarowości danych z uzyskanymi w Części I anotacjami. Celem ćwiczenia jest wstępna analiza oetykietowanych danych oraz ich przydatności do automatycznego przetwarzania (np. klasyfikacja).

Plan realizacji ćwiczenia

Word Embeddings (3 pkt)

1. Wykonać osadzenia słów w anotowanym korpusie (co najmniej 2 różne modele) **[1pkt]**
    a. Word2vec
        i. dla języka polskiego: https://dsmodels.nlp.ipipan.waw.pl
        ii. dla języka angielskiego: https://radimrehurek.com/gensim/index.html
    b. Fasttext
        i. dla języka polskiego: https://huggingface.co/clarin-pl/fastText-kgr10
        ii. dla języka angielskiego: https://fasttext.cc
    c. GloVe dla języka angielskiego: https://github.com/stanfordnlp/GloVe

2. Wizualizacja danych za pomocą t-SNE z odniesieniem do etykiet w ramach anotacji. Wykonać wykres interaktywny, w którym po najechaniu na punkt można odczytać słowo i / lub anotację. **[0.5pkt]**

3. Wygenerować listy k-najbardziej podobnych dla słów zaanotowanych w korpusie i porównać otrzymane listy dla co najmniej 2 różnych modeli przestrzeni wektorowych **[1pkt]**

4. Opracować krótką dyskusję otrzymanych rezultatów **[0.5pkt]**

Pytania pomocnicze do dyskusji:

1. Czy osadzenia pre-trenowane na dużych korpusach dobrze odwzorowują znaczenie słów w utworzonym korpusie dziedzinowym?
2. Czy w zebranym korpusie tekstowym występuje grupowanie słów związanych z anotacją?
    - Przykładowo, w kontekście wydźwięku, czy występuje grupowanie na słowa pozytywne i negatywne? Jeśli nie, to dlaczego osadzenia mogą nie oddawać emocjonalnego znaczenia słów?
3. Na czym polegają różnice między wygenerowanymi za pomocą różnych modeli listami podobieństwa i z czego one wynikają?
4. Jak moglibyśmy ulepszyć osadzenia dla rozwiązywanego zadania?

Text Embeddings (2 pkt)

1. Wygenerować osadzenia zdań lub całych tekstów (wykorzystać do tego 2 różne modele) **[0.5pkt]**
    a. Fasttext (można wykorzystać modele z Części I)
    b. Uśrednione wektory Word2Vec (można wykorzystać modele z Części I)
    c. Universal Sentence Encoder

2. Dla każdego z modeli, wizualizacja danych za pomocą t-SNE z odniesieniem do etykiet w ramach anotacji. Wykonać wykresy interaktywne, w którym po najechaniu na punkt można odczytać zdanie (tekst) i / lub anotację. **[0.5pkt]**

3. Proszę przeprowadzić analizę otrzymanych osadzeń w taki sposób, aby przeprowadzić dyskusję na temat właściwości badanych modeli osadzeń i odpowiedzieć na zadane pytania pomocnicze (patrz poniżej). **[1pkt]**

Pytania pomocnicze do dyskusji

1. Czy są zdania, które model uznał za podobne, ale w rzeczywistości różnią się znaczeniem?
2. Czy są zdania, które są semantycznie podobne, ale model uznał je za odległe, bo użyto innych słów?
3. Czy zdania o różnej długości, ale podobnym sensie, są traktowane przez model podobnie?
4. Czy zauważasz różnicę w wartościach podobieństwa między krótkimi a długimi zdaniami? Zastanów się, czy długość zdania wpływa na „wyrazistość" jego wektora.
5. Czy opracowane osadzenia zdań nadają się do wybranego zadania (dla którego prowadziliście anotację?

Proszę uzasadnić swoje odpowiedzi.

Sugerowana literatura

1. Wprowadzenie do Word Embeddings

Fragment książki D. Jurafsky o modelach przestrzeni wektorowych
https://web.stanford.edu/~jurafsky/slp3/6.pdf

Notatki do wykładu NLP, Stanford CS224N
https://web.stanford.edu/class/cs224n/readings/cs224n_winter2023_lecture1_notes_draft.pdf

Efficient Estimation of Word Representations in Vector Space
https://arxiv.org/pdf/1301.3781

Distributed Representations of Words and Phrases and their Compositionality
https://arxiv.org/abs/1310.4546

Bag of Tricks for Efficient Text Classification
https://arxiv.org/pdf/1607.01759

2. Eksploracja modeli przestrzeni wektorowych

Tutorial do ćwiczeń z NLP, Stanford
https://web.stanford.edu/class/cs224n/assignments/a1_preview/exploring_word_vectors.html

Algorytm klasteryzacji HDBSCAN
https://hdbscan.readthedocs.io/en/latest/how_hdbscan_works.html

Redukcja wymiarowości za pomocą t-SNE
https://medium.com/@sachinsoni600517/mastering-t-sne-t-distributed-stochastic-neighbor-embedding-0e365ee898ea

3. Universal Sentence Encoder

Artykuł naukowy o USE
https://arxiv.org/abs/1803.11175

Artykuł podsumowujący działanie USE
https://fritz.ai/google-universal-sentence-encoder/